14. Pour aller plus loin

Cette partie est facultative. Elle permet aux participants qui le souhaitent d'approfondir le projet au-delà des exigences minimales du Module 1.

L'objectif est d'améliorer la robustesse, la précision et la réutilisabilité du pipeline sans rendre ces extensions obligatoires pour la validation du module.

Axe 1 — Approfondir la qualité des données

- Détecter les doublons approximatifs, notamment lorsque le même bien apparaît sous des identifiants différents.
- Identifier les conflits entre sources et proposer une stratégie de rapprochement documentée.
- Définir un score global de qualité reposant sur des règles explicites et justifiées.
- Produire un rapport détaillé retraçant chaque anomalie, correction et décision de validation.
- La similarité doit combiner plusieurs attributs (ville, type, surface, prix, date) ;
- Le seuil de rapprochement doit être **justifié** et testé sur les cas ambigus du fichier formateur ;
- Les conflits entre sources doivent être **signalés**, pas résolus arbitrairement.

Axe 2 — Rendre les règles configurables

● Séparer les règles métier du code Python.
● Permettre de modifier les seuils et les catégories autorisées sans modifier les fonctions de traitement.
● Définir plusieurs niveaux de gravité : erreur bloquante, avertissement et anomalie corrigeable. ● Ajouter des tests automatisés pour vérifier chaque règle, y compris les cas limites.

Axe 3 — Améliorer l'ingestion des données

- Ajouter la prise en charge du format **Parquet** (lecture et export), en complément de CSV, Excel et JSON.
- Mettre en place un **registre de sources** (fichier YAML ou JSON) décrivant pour chaque flux : format, encodage, séparateur, schéma attendu, règles de normalisation spécifiques. Le pipeline lit le registre et s'adapte sans modification de code.
- Simuler une **source API locale** (petit serveur HTTP renvoyant du JSON) pour apprendre l'ingestion de données via requêtes HTTP sans dépendre d'un service externe.
- Gérer l'**ajout d'une nouvelle source** sans toucher au code des modules existants : seul le registre est modifié.

Axe 4 — Renforcer la fiabilité du pipeline

● Remplacer les affichages de diagnostic par un système de journalisation avec `logging`. ● Rendre les traitements reproductibles et idempotents : relancer le pipeline ne doit pas créer de doublons supplémentaires.

- Ajouter des tests automatisés pour les conversions, les règles métier et les exports.
- Mesurer le temps d'exécution et comparer plusieurs stratégies de traitement.

Axe 5 — Préparer une évolution vers le Machine Learning

- Étudier l'effet des valeurs manquantes et des valeurs extrêmes sur les statistiques descriptives.
- Comparer les distributions avant et après nettoyage.
- Préparer un jeu de données documenté pour un futur projet de prédiction immobilière.
- Justifier quelles données peuvent être conservées pour un modèle et lesquelles doivent être exclues.
- Comparer les distributions de prix **avant et après** séparation ventes / locations, et **avant et après** rapprochement des doublons : mesurer l'effet du pipeline sur les statistiques descriptives.

Conditions de réalisation

Ces extensions sont indépendantes : chaque participant peut en choisir une ou plusieurs selon son niveau et le temps disponible.

Elles ne remplacent pas les exigences obligatoires du projet. Toute extension doit être accompagnée d'une explication technique, de tests adaptés et d'une démonstration de son utilité.

Les modèles de Machine Learning, les architectures distribuées et les déploiements complexes restent hors du périmètre de cette section ; ils pourront être étudiés dans les modules suivants.